

RAPORT DE LABORATOR NR. 6

(Template standard – max. 3 pagini)

Contents

RAPORT DE LABORATOR	1
Pagina de titlu	2
1. Scopul laboratorului	Error! Bookmark not defined.
2. Descrierea sistemului și metodologia	Error! Bookmark not defined.
2.1 Sistemul / modelul utilizat	Error! Bookmark not defined.
2.2 Date și semnale analizate	Error! Bookmark not defined.
2.3 Metoda de lucru	Error! Bookmark not defined.
3. Rezultate și analiză	Error! Bookmark not defined.
4. Concluzii	Error! Bookmark not defined.
Observații pentru studenți	Error! Bookmark not defined.

Pagina de titlu

Universitatea: UTCN

Facultatea / Departamentul: Facultatea de Inginerie Industrială, Robotica și Managementul Producției

Disciplina: Design of digital twins

Laboratorul nr.: 6

Titlul laboratorului: Digital Twin monitoring - Grafana-ML-Matlab

Student:

Nume și prenume: Vaida Diana-Laura

Grupa / An: m_129_11/2026

Data: 26.01.2026

1. Scopul laboratorului

Scopul acestui laborator este utilizarea metodelor de Machine Learning pentru analiza datelor provenite de la un geamăn digital (Digital Twin) . Obiectivul principal constă în antrenarea unui clasificator capabil să identifice automat starea de funcționare a unei pompe (Normal vs. Seal Leakage) pe baza indicatorilor statistici extrași din semnalele de presiune și curent .

2. Descrierea sistemului și metodologia

2.1 Sistemul / modelul utilizat

În această etapă, mediul de lucru principal a fost MATLAB, utilizat pentru procesarea datelor salvate anterior în fișierul pump_data_lab.mat.

- Modelul de date: Conține 20 de seturi de observații (simulări), fiecare având o etichetă de stare și valorile caracteristice (features) .

2.2 Date și semnale analizate

Analiza s-a bazat pe doi indicatori principali extrași în etapa precedentă :

- Media Presiunii la Ieșire: Reflectă stabilitatea hidraulică a sistemului. O scădere a mediei sub un prag critic este corelată cu defectul de tip "seal leakage".
- RMS Curent Motor: Reflectă semnătura electrică a efortului depus. Modificările în valoarea RMS indică variații de sarcină provocate de defect.

2.3 Metoda de lucru


1. Pregătirea datelor: Încărcarea matricei features (20x2) și a vectorului labels (20x1).
2. Reprezentarea grafică: Utilizarea funcției gscatter pentru a vizualiza distribuția datelor și a observa separabilitatea claselor "Normal" și "Seal Leakage".

3. Antrenarea modelului ML: S-a utilizat algoritmul Decision Tree (Arbore de Decizie) prin funcția `fitctree`. Acest model stabilește automat pragurile optime de decizie fără intervenție manuală .
4. Validarea și Salvarea: Verificarea acurateții clasificării și salvarea modelului sub numele `pump_ml_model.mat` pentru utilizare în monitorizarea timp-real.

3. Rezultate și analiză

Prin vizualizarea datelor, s-a constatat că regimul de defect determină o grupare distinctă a punctelor la valori de presiune semnificativ mai mici față de regimul normal.

- Analiza valorilor: Pentru starea normală, presiunea medie s-a situat peste 80.5 psi, în timp ce pentru "seal leakage", valorile au scăzut sub 80 psi.
- Verdictul modelului: Arborele de decizie a identificat o regulă de tip: Dacă Presiune < Prag atunci Stare = Defect.



4. Concluzii

Laboratorul 6 a demonstrat eficiența tehnicilor de Machine Learning în diagnosticarea automată a sistemelor industriale. S-a demonstrat că alegerea corectă a indicatorilor (Media și RMS) permite clasificarea precisă a defectelor. Utilitatea majoră constă în capacitatea sistemului de a genera alarme automate de mentenanță preventivă imediat ce noile date de la senzori sunt comparate cu modelul antrenat. O limitare a metodei este dependența de calitatea datelor sintetice, fiind necesară o bază de date cât mai diversificată pentru a acoperi toate scenariile de operare.

